


## SAÉ-5.03-Data mining

Comment prédire le risque d'hypertension à partir de variables cliniques, comportementales et familiales ?



Definition Solutions

# Qu'est ce que l'hypertension artérielle et quelles sont les solutions ?

L'hypertension artérielle est une maladie qui se caractérise par une élévation anormale et persistante de la pression du sang dans les artères (vaisseaux partant du cœur servant à distribuer le sang à tout le corps).



On peut généralement commencer à parler d'hypertension lorsque la pression artérielle dépasse les 140 mmHg, elle est mesurée de manière répétée au repos (mmHG: le millimètre de mercure, unité de mesure de la pression). Cela oblige le cœur à travailler davantage pour distribuer le sang dans tout le corps.




Sur le long terme, elle va augmenter grandement le risque de maladies cardiovasculaires graves, comme les infarctus, les accidents vasculaires cérébraux (AVC), l'insuffisance rénale, etc...



Les facteurs de risques sont: une alimentation déséquilibrée (consommation de sel excessive de graisses saturées), la consommation insuffisante de fruits et légumes, la sédentarité, la consommation de tabac, d'alcool, le surpoids et l'obésité.



Avoir une activité physique régulière, par exemple, faire 30 minutes de marche régulièrement va diminuer cette pression de 5 à 10 mmHG.



Adoptez une alimentation saine : réduisez le sel et les aliments transformés, limitez graisses saturées et sucres. Favorisez les fruits, légumes, fibres et aliments riches en potassium



Réduire sa consommation de tabac, c'est déjà faire baisser sa tension. Chaque cigarette en moins compte



# Présentation de notre jeu de données

Dans le cadre de notre projet de Data Mining, nous avons utilisé un jeu de données intitulé "Hypertension Risk Prediction Dataset", disponible sur la plateforme Kaggle.

Ce jeu de données est synthétique mais réaliste, conçu pour permettre aux chercheurs et aux data scientists d'analyser les facteurs de risque associés à l'hypertension artérielle.

Le dataset contient 1 985 observations (lignes) et 11 variables (colonnes). Ces variables représentent des caractéristiques cliniques, comportementales et familiales liées à la santé des individus. L'objectif principal est de comprendre comment ces facteurs influencent la probabilité qu'une personne souffre d'hypertension.

Age : L'âge de l'individu (en années).

Salt\_Intake : Quantité moyenne de sel consommée par jour.

Stress\_Score : Un score numérique représentant le niveau de stress de l'individu (de 1 à 10).

BP\_History : Indique si l'individu a des antécédents de problèmes de tension artérielle.

Sleep\_Duration : Nombre moyen d'heures de sommeil par nuit.

BMI : L'indice de masse corporelle (Body Mass Index) de l'individu.

Medication : Indique si la personne prend actuellement un traitement médicamenteux lié à la tension.

Family\_History : Précise si l'individu a des antécédents familiaux d'hypertension.


Exercise\_Level : Niveau d'activité physique (faible, modéré ou élevé).

Smoking\_Status : Indique si l'individu est fumeur ou non

Has\_Hypertension : Variable cible indiquant si la personne souffre d'hypertension artérielle.



# Répartition des tâches :



## **Préparation et nettoyage du jeu de données pour l'analyse exploratoire**

Dans un premier temps, nous avons procédé au nettoyage des données afin de préparer notre jeu de données pour l'analyse. Par exemple, dans la colonne Medicament, certaines valeurs manquantes (NaN) pouvaient entraîner des incohérences ou des erreurs lors des étapes suivantes, notamment lors de la visualisation et de la modélisation. Pour résoudre ce problème, nous avons remplacé ces valeurs manquantes par la valeur "NON", indiquant l'absence de médicament, ce qui permet de conserver toutes les observations sans créer de biais.

Ensuite, nous avons défini nos variables catégorielles et numériques. Cette distinction est essentielle pour appliquer correctement les techniques de prétraitement et choisir les méthodes d'analyse ou de modélisation adaptées à chaque type de variable. Les variables catégorielles contiennent des informations qualitatives (BP\_History, Medication, Family\_History, Exercise\_Level, Smoking\_Status, Has\_Hypertension), tandis que les variables numériques représentent des mesures quantitatives (Age, Salt\_Intake, Stress\_Score, Sleep\_Duration, BMI).

Pour préparer nos variables catégorielles à la modélisation, nous avons ensuite appliqué un encodage numérique avec le LabelEncoder de scikit-learn. La plupart des algorithmes de machine learning ne peuvent pas traiter directement des chaînes de caractères, ils nécessitent des valeurs numériques. Le LabelEncoder transforme chaque catégorie d'une variable en un entier unique, permettant ainsi au modèle de travailler avec ces informations tout en conservant la distinction entre les différentes catégories.

Enfin, nous avons identifié notre variable cible, Has\_hypertension, et nous avons étudié son lien avec les différentes caractéristiques (features) de notre jeu de données. Cette étape d'analyse exploratoire permet de visualiser les comportements et les tendances, d'identifier des relations potentielles entre les variables et la variable cible, et de mieux comprendre les facteurs pouvant influencer l'hypertension. Cela constitue une étape clé avant de passer à la modélisation prédictive.


### **Quelles sont les statistiques descriptives de nos variables numériques ?**

|                | Moyenne   | Variance   | Écart-type | Min  | Max  |
|----------------|-----------|------------|------------|------|------|
| Age            | 50.341058 | 377.992996 | 19.442042  | 18.0 | 84.0 |
| Salt_Intake    | 8.531688  | 3.979656   | 1.994907   | 2.5  | 16.4 |
| Stress_Score   | 4.979345  | 9.874069   | 3.142303   | 0.0  | 10.0 |
| Sleep_Duration | 6.452242  | 2.378403   | 1.542207   | 1.5  | 11.4 |
| BMI            | 26.015315 | 20.365874  | 4.512857   | 11.9 | 41.9 |

- L'Âge moyen est d'environ 50 ans, ce qui montre une maturité de nos individus, le plus jeune a 18 ans tandis que le plus âgé a 84 ans.
- La consommation de sel s'élève à environ 8g, ce qui reste inférieur au seuil de provocation de l'HTA qui s'élève à 12g.
- Le niveau de stress est de 5 environ, relevant un stress chez la moitié de nos individus.
- Nos individus dorment en moyenne 6h par nuit, ce qui est impactant pour santé car un adulte se doit de dormir au minimum entre 7 et 9h par nuit pour éviter l'HTA.
- L'indice de masse corporelle, appelé aussi BMI, nous donne l'information si l'individu est en surpoids ou non, à partir de 25 cela devient un facteur pouvant causer l'HTA.

**Quelle est la proportion d'individus hypertendus par rapport aux non-hypertendus ?**

Répartition de la variable cible (Has\_Hypertension)



Ce graphique représente la répartition de la variable cible Has\_Hypertension, qui indique si un individu est atteint d'hypertension ou non.


On observe que le jeu de données est assez équilibré, avec 1 032 individus hypertendus contre 953 non hypertendus.

Cette répartition homogène est un atout pour la suite de l'analyse, car elle limite les risques de biais de classe lors de la modélisation.

En d'autres termes, le modèle pourra apprendre de manière équitable à distinguer les individus hypertendus des non hypertendus, ce qui renforce la fiabilité des futures prédictions.

**Quelle est la proportion d'individus fumeurs par rapport aux non-fumeurs ?**

Répartition de la variable cible (Smoking\_Status)



Le second graphique montre la répartition des individus selon leur statut tabagique (Smoking\_Status).

On constate que la majorité des personnes de l'échantillon sont non-fumeuses (1 417 individus), contre 568 fumeurs.


Cette différence traduit une surreprésentation des non-fumeurs dans le jeu de données.

Il sera donc intéressant de vérifier, dans les analyses suivantes, si le tabagisme exerce tout de même une influence significative sur la probabilité de développer une hypertension, malgré cette distribution déséquilibrée.



# Quelles sont nos variables corrélées entre elles ?

Matrice de corrélation des variables du jeu Hypertension



Nous observons que les antécédents personnels de tension artérielle représentant 0.44 et familiaux 0.28 sont les principaux facteurs prédictifs de l'hypertension. Le tabagisme, le stress et un IMC (l'indice de masse corporelle) élevé montrent également des corrélations positives notables.

Contrairement aux attentes, nous constatons une légère corrélation négative avec l'âge (-0.21), ce qui pourrait indiquer un biais dans notre échantillon.

La consommation de sel et l'activité physique présentent des liens étonnamment faibles avec la maladie.

Ces résultats nous orientent vers l'importance cruciale des antécédents médicaux dans notre diagnostic. Ce sont donc des variables que nous allons croiser par la suite afin de vérifier la répartition entre nos individus et leurs antécédents familiaux.


|                  | count  | mean      | std       | min  | 25%  | 50%  | 75%  | max  |
|------------------|--------|-----------|-----------|------|------|------|------|------|
| Has_Hypertension |        |           |           |      |      |      |      |      |
| No               | 953.0  | 46.079748 | 18.954555 | 18.0 | 30.0 | 43.0 | 61.0 | 84.0 |
| Yes              | 1032.0 | 54.276163 | 19.061957 | 18.0 | 38.0 | 56.0 | 70.0 | 84.0 |

Nous avons un jeu de données assez équilibré avec une variable binaire ce qui nous donne le choix d'utiliser la régression logistique

**Est-ce que l'hérédité (les antécédents familiaux, antécédents personnels) est un facteur prédominant chez les patients déjà diagnostiqués comme hypertendus ?**

**Répartition selon les antécédents familiaux**


Répartition des patients hypertendus selon leurs antécédents familiaux



Nous observons que près des deux tiers (63,2%) des patients hypertendus déclarent avoir des antécédents familiaux de cette pathologie. Cette majorité confirme que les antécédents familiaux constituent un facteur de risque prédominant dans notre échantillon. L'hérédité semble d'après nous jouer un rôle crucial dans la survenue de l'hypertension.


**Répartition de l'historique de tension artérielle**

Répartition de l'historique de tension chez les patients hypertendus




Ce graphique nous montre que la majorité absolue (51,2%) des patients hypertendus avaient un historique classé "Hypertension" avant leur diagnostic. Si l'on y ajoute les patients en "Préhypertension" (27,7%), cela signifie que plus de 78% des patients se situaient déjà dans un spectre à risque. Cela souligne l'importance du suivi médical pour les personnes appartenant à ces catégories.

## **Comment la probabilité d'hypertension varie-t-elle avec l'âge ?**



Nous observons que notre échantillon présente une distribution d'âge très bien équilibrée entre 30 et 70 ans, avec un petit pic visible autour de la cinquantaine. La population âgée de 20 à 30 ans est sous-représentée, tandis que les seniors de 70-80 ans sont également moins nombreux.




La distribution chez les patients hypertendus révèle une nette surreprésentation dès les 50 à 70 ans, avec un pic marqué autour de 60 ans. À l'inverse, les jeunes adultes (entre 20 et 40 ans) sont très peu représentés parmi les hypertendus. Cette courbe confirme l'effet de l'âge comme facteur de risque majeur, montrant que l'hypertension augmente significativement après 50 ans dans notre population d'étude.



**Les individus avec un BMI élevé sont-ils *plus susceptibles d’être hypertendus* ?**

```
bdd_Hypertension[bdd_Hypertension["BMI"]>25].shape[0]/bdd_Hypertension.shape[0]
```

0.5808564231738035



L’analyse du graphique ci-dessus montre la distribution de l’indice de masse corporelle (BMI) selon la présence ou non d’hypertension chez les individus du jeu de données. On observe que, de manière générale, les individus hypertendus (catégorie “Yes”) présentent un BMI moyen légèrement plus élevé que ceux n’ayant pas d’hypertension (“No”). La forme plus étalée de la violon plot chez les hypertendus indique également une plus grande variabilité des valeurs de BMI dans ce groupe.

Ce constat est cohérent avec la littérature médicale, qui met en évidence une corrélation entre un excès de masse corporelle et un risque accru d’hypertension. Cette observation est renforcée par la requête réalisée en amont, qui révèle que 58 % des individus de notre échantillon ont un BMI supérieur à 25, seuil à partir duquel on considère qu’une personne est en surpoids. Ce résultat suggère donc qu’une majorité de la population étudiée se situe dans une catégorie de risque potentiel vis-à-vis de l’hypertension.

Ainsi, il semble exister une tendance selon laquelle un BMI élevé est associé à une plus forte probabilité de développer de l’hypertension.

# CONCLUSION

L'hypertension artérielle reste un problème de santé majeur, mais elle peut être prévenue et contrôlée grâce à une meilleure compréhension des facteurs de risque. Grâce à l'Exploratory Data Analysis (EDA) menée sur notre dataset, nous avons pu :

Identifier les variables numériques et catégorielles importantes, comme l'âge, le BMI, les antécédents familiaux et l'historique médical.

Visualiser la distribution des patients hypertendus et non hypertendus, en détectant les tendances et les valeurs extrêmes grâce à des histogrammes, boxplots et pie charts.

Mettre en évidence les corrélations entre les différentes variables et la présence d'HTA via des heatmaps et des analyses de corrélation.

En résumé, l'EDA nous a permis de transformer les données brutes en informations exploitables, révélant des patterns et relations essentielles pour comprendre l'HTA. Ce travail constitue une base solide pour la modélisation prédictive future, la prise de décision médicale et la prévention personnalisée de l'hypertension.

Dans notre analyse exploratoire (EDA), nous avons observé que l'âge, le BMI, la durée de sommeil et le score de stress jouent un rôle déterminant dans le risque d'HTA.

Les variables comportementales comme le niveau d'exercice, la consommation de sel et le statut tabagique apportent également des indications précieuses.

Les antécédents familiaux et l'historique de tension artérielle se révèlent être des facteurs particulièrement corrélés à l'hypertension.

Ainsi, ces différentes caractéristiques nous ont permis de mieux comprendre les profils les plus à risque et de poser les bases d'une future modélisation prédictive.

Les individus ayant un stress élevé et peu de sommeil sont-ils particulièrement à risque ?

Quelles variables semblent les plus pertinentes pour prédire l'hypertension ?

C'est ce que nous allons voir dans les prochaines parties...

